

VERIFICA AI: Bot de Inteligência Artificial para Detecção de Fake News em Redes Sociais

Aquiles Alves de Melo Oliveira, Isabella dos Santos Caruso, Vitor Emanuel da Silva Rodrigues,
Abraão Lima Sousa (Orientador), Victor Eduardo Alves da Silva Carvalho (Coorientador)

Instituto Federal de Ciências e Tecnologia do Piauí, Teresina - PI

RESUMO

A desinformação representa uma ameaça global, que devido a inteligência artificial, se projeta como a principal preocupação para 2027 (WORLD ECONOMIC FORUM, 2025). No Brasil a desinformação nas redes sociais é ainda mais grave, 57% da população não consegue identificar conteúdos falsos, conforme dados da OCDE. Diante dessa problemática, este estudo desenvolveu o "Verifica AI", um agente de IA integrado ao *Instagram*. Sua função é verificar a veracidade de postagens multimodais (texto, imagem e vídeo) diretamente na plataforma e classificar a desinformação corretamente, com base nas sete categorias da UNESCO. O protótipo utiliza a *Graph API* da *Meta* para comunicação via Mensagem Direta (DM), o *Instaloader* para *download* do conteúdo e o *Gemini Flash 2.5* para analisar imagens e vídeos. Em seguida, o algoritmo submete o conteúdo analisado a uma busca em diversas fontes relacionadas ao tema na *internet*, reunindo evidências para validação. Os resultados da pesquisa são comparados com o conteúdo original, permitindo concluir se a notícia constitui ou não desinformação. O protótipo foi concluído com sucesso e está disponível no perfil do *Instagram* @verifica_ai_. Sua confiabilidade foi avaliada através de uma matriz de confusão, os resultados obtidos com 200 postagens (150 verdadeiras e 50 falsas), indicaram acurácia de 97%, precisão de 98% e sensibilidade de 98%. Isso permite concluir que o sistema classifica corretamente a maioria dos casos. O protótipo alcançou todos os objetivos, com desempenho funcional robusto que supera as limitações de ferramentas como *Meta AI* e *AI Studio*. Em contrapartida, são evidentes as limitações do uso de tecnologias gratuitas, como as restrições operacionais (limites diários de uso), a latência ocasional nas respostas e a ocorrência, ainda que rara, de falhas críticas, o que inviabiliza a escalabilidade da solução.

Palavras-Chave: *fake-news*, desinformação, inteligência artificial.

I. INTRODUÇÃO

O surgimento da *internet* e a evolução dos *smartphones* geraram grandes impactos ao mundo moderno. Como resultado, vivemos na era digital, onde a maioria das pessoas está conectada por meio de celulares e tem fácil acesso a redes sociais. Segundo o relatório da "*We Are Social*", há aproximadamente 5,45 bilhões de usuários de *internet* no mundo somente em 2024, representando 67,1% da população global (WE ARE SOCIAL, 2024). No entanto, essa conectividade intensifica a ameaça das "*Fake news*".

Segundo a UNESCO, "*Fake News*" consiste na divulgação de informações falsas, feitas com o propósito de confundir ou manipular as pessoas. O uso do termo "*Fake News*" para referir a propagação de notícias falsas, apesar de ser o mais popular, não é recomendado, pois frequentemente é usado para desacreditar e depreciar o jornalismo. No lugar, a UNESCO sugere o uso dos termos "desinformação" ou "informação incorreta". (UNESCO, 2018).

O fenômeno da desinformação é agravado pelo uso mal-intencionado da inteligência artificial, que facilita a criação de *deepfake* que usam imagens, vídeos ou áudios cada vez mais realistas. Isso amplia consideravelmente o alcance e impacto de notícias falsas no meio digital, principalmente nas redes sociais. A facilidade com que os usuários compartilham conteúdo, aliada à rápida viralização de temas polêmicos, faz das redes sociais o principal meio de disseminação de desinformação da atualidade. (DELMAZO, 2018).

O relatório da *Global Risks Report 2025* destaca que a desinformação é a principal preocupação para 2027, a pesquisa aponta que está cada vez mais difícil distinguir conteúdos digitais gerados por inteligência artificial. (WORLD ECONOMIC FORUM, 2025). Enquanto isso, o Brasil é o país que mais cai em desinformação no mundo, segundo a Organização para a Cooperação e Desenvolvimento Econômico, 57% da população não sabe identificar conteúdos falsos. (OCDE, 2024).

Contextos como a pandemia e períodos eleitorais são a prova de que a desinformação não apenas distorce a realidade, mas também contribui para a polarização, espalha pânico e leva a sociedade a tomar decisões erradas que prejudicam diretamente a saúde, as finanças, a segurança e até mesmo a democracia.

Considerando a problemática apresentada, o objetivo deste estudo é desenvolver uma ferramenta que combata ativamente a desinformação. A solução proposta deve ter as características de ser didática, confiável e ágil e a funcionalidade de verificar a veracidade de conteúdos (*posts* e mensagens) publicados diretamente na rede social.

II. OBJETIVO

Desenvolver uma ferramenta gratuita que combata a desinformação dentro das redes sociais. Ela deve identificar e classificar a desinformação de conteúdos multimodais (texto,

imagens e vídeos), incluindo posts, em conformidade com as sete categorias da UNESCO.

Objetivos específicos:

- Selecionar a rede social alvo e configurar as permissões oficiais necessárias para envio e recebimento de mensagens diretas (DM);
- Desenvolver o backend para processar conteúdos multimodais, convertendo áudio, vídeo e imagem em texto para análise;
- Integrar LLM do *Gemini* ao algoritmo, habilitando a análise com inteligência artificial;
- Projetar e ajustar *prompts* com finalidade de identificar e classificar desinformação;
- Adotar as diretrizes da UNESCO para classificar dentre as sete categorias;
- Avaliar a confiabilidade e desempenho do protótipo;

III. DESCRIÇÃO DE MATERIAIS E MÉTODOS

Com o objetivo de encontrar um método eficaz que verifica a veracidade de postagens diretamente nas redes sociais, foram analisadas as soluções existentes.

A. Análise das Soluções Existentes

O *Grok* da rede social X é capaz de participar de conversas dentro da própria plataforma. Quando solicitado, o *Grok* analisa *posts* (vídeo, imagem e texto) e avalia a veracidade do conteúdo publicado. A resposta é enviada dentro do *post* em resposta a requisição do usuário.

IMAGEM 1 - RESPOSTA DO GROK NO X PARA ANÁLISE DE POST




Fonte: Próprio Autor (2025).

A *Meta* possui o *chatbot* da *Meta AI*, que funciona dentro do *Instagram*. Sua vantagem reside na integração nativa, que permite aos usuários interagirem diretamente com a IA, sem a necessidade de alternar entre aplicativos. No entanto, essa solução apresenta limitações, como a incapacidade de analisar imagens enviadas e de verificar

postagens diretamente no *Instagram*. Sendo necessário o usuário precisa escrever o conteúdo de forma manual.

IMAGEM 2 - RESPOSTA DO META AI PARA ANÁLISE DE POST



Fonte: Próprio autor, adaptado de Instagram (2025).

Testou-se também a criação de um agente de IA nativo por meio do *AI Studio* da *Meta*. No entanto, o modelo revela não possuir a capacidade de analisar conteúdos de *posts* dentro da própria plataforma, além de apresentar alucinações e fornecer respostas incorretas.

B. Definição da Solução

Com base na análise dos meios existentes de verificação de desinformação nas redes sociais, nota-se que o *Instagram* não apresenta soluções eficazes. Por isso, buscou-se desenvolver uma ferramenta que adota uma abordagem semelhante à do *Grok*, mas adaptada para o *Instagram*.

A solução proposta consiste no uso de um agente de inteligência artificial (IA) integrado a um perfil da rede social. Um agente de IA é um sistema de *software* que utiliza inteligência artificial para atingir objetivos e completar tarefas. Ele é capaz de demonstrar raciocínio, planejamento, memória e um nível de autonomia para tomar decisões, aprender e se adaptar. Além disso, eles processam informações multimodais, como texto, voz e vídeo, e podem executar fluxos de trabalho complexos. (GOOGLE CLOUD, 2025)

Ao se desenvolver um agente de IA, temos uma ferramenta que permite o recebimento de imagens, vídeos e textos diretamente por DM, o processamento deste conteúdo multimodal e o retorno de uma conclusão com as respectivas fontes. Assim, o requisito central do problema é atendido, garantindo a verificação de posts dentro da rede social e a preservação da experiência do usuário.

C. Desenvolvimento do Protótipo

Inicialmente, foram definidos os requisitos funcionais e não funcionais do projeto:

IMAGEM 3 - REQUISITOS FUNCIONAIS DO PROTÓTIPO




Fonte: Próprio Autor (2025).

Os requisitos definiram as ferramentas utilizadas durante a metodologia. Em vista disso, o primeiro passo foi usar o *Graph API* do *Meta for Developers*, o qual integrou *Direct Message* (DM) por meio de webhook para recepção e envio de mensagens em tempo real. Essa configuração envolveu permissões oficiais para acessar mensagens diretas entre o perfil do protótipo e os usuários, implementando um endpoint seguro que notifica o backend imediatamente quando um post ou mensagem é compartilhado.

O próximo passo foi desenvolver o backend, responsável por baixar o conteúdo analisado. A ferramenta *Instaloader* foi usada para download de imagens e vídeos. Ele acessa os *URLs* dos posts compartilhados via DM e baixa os arquivos em nuvem de forma temporária e segura, sem violar os termos de uso do *Instagram*. Isso viabiliza a análise de conteúdos que não são diretamente acessíveis via API.


IMAGEM 4 - FLUXO DO PROCESSO DE EXTRAÇÃO DE DADOS



Fonte: Próprio Autor (2025).

Mesmo após o processamento inicial, três tipos de conteúdo (texto, imagem e vídeo) foram identificados. Por isso, o modelo *Gemini Flash 2.5*, que utiliza recursos avançados de visão computacional e compreensão multimodal, foi empregado para analisar o conteúdo. Na análise de imagens, o modelo entende o contexto visual de forma nativa e, na análise de vídeos, processa a sequência de quadros e o áudio para uma compreensão do conteúdo.


IMAGEM 5 - FLUXO DO PROCESSO DE PADRONIZAÇÃO DE DADOS



Fonte: Próprio Autor (2025).

Testes preliminares foram conduzidos para verificar a integração do *Gemini* com o perfil do *Instagram*. A etapa de integração do *Gemini Flash 2.5* foi confirmada com sucesso por meio de testes, apresentados na imagem 6.


IMAGEM 6 - TESTES DA INTEGRAÇÃO DO GEMINI AO INSTAGRAM



Fonte: Próprio Autor (2025).

O algoritmo desenvolvido permite a definição de diretrizes para o *chatbot*, incluindo a forma como ele deve identificar e classificar desinformação em publicações, com o uso de prompts (Imagem 7) específicos para este fim.

IMAGEM 7 - PRIMEIRO PROMPT USADO NO GEMINI




Fonte: Próprio Autor (2025).

O *Gemini* pode analisar o conteúdo, mas o modelo gratuito *Flash 2.5* não possui conectividade direta com a *internet*. Para possibilitar a verificação do conteúdo com fontes recentes, o algoritmo submete o conteúdo analisado a uma busca em múltiplas fontes relacionadas ao tema na *internet*, reunindo evidências para validação. Em seguida, por meio de *prompts* previamente definidos, os resultados da pesquisa são comparados com o conteúdo original, permitindo concluir se a notícia é ou não uma desinformação.

Se o modelo do *Gemini* avaliar com mais de 95% de certeza que o conteúdo é desinformação, o sistema o categoriza conforme uma das sete categorias recomendadas pelo Manual da UNESCO:

1. Sátira e paródia: Conteúdo humorístico criado sem a intenção de causar danos, mas que tem o potencial de enganar;
2. Conexão falsa: Ocorre quando manchetes, imagens visuais ou legendas não correspondem ao conteúdo. Isso é frequente em manchetes do tipo "click-bait";
3. Conteúdo enganoso: Uso enganoso de informações, cortando fotos ou selecionando citações e estatísticas seletivamente, para enquadrar problemas ou indivíduos de determinadas maneiras;
4. Contexto falso: Conteúdo genuíno que é compartilhado com informações contextuais falsas, sendo visto sendo reciclado fora de seu contexto original;
5. Conteúdo impostor: Ocorre quando fontes genuínas como nomes de jornalistas ou logotipos de organizações respeitadas são apropriados indevidamente em materiais falsos;
6. Conteúdo manipulado: Quando o conteúdo genuíno (texto, fotos ou vídeos) é manipulado digitalmente para enganar;
7. Conteúdo fabricado: Conteúdo que é 100% falso, destinado a enganar e prejudicar, como sites de notícias completamente fabricados;


IMAGEM 8 - FLUXO DO FUNCIONAMENTO DO PROTÓTIPO



Fonte: Próprio Autor (2025).

Após a finalização do processo de *backend*, iniciou-se a criação da identidade visual. Também foi realizada nessa etapa a finalização da configuração do perfil responsável por receber as mensagens. Assim definiu-se o nome do perfil: "Verifica AI". Após os de ajuste de *prompts* e refinamento do algoritmo, o protótipo foi finalizado com sucesso.

IMAGEM 9 - EQUIPE DESENVOLVENDO BACKEND E O DESIGN




Fonte: Próprio Autor (2025).

IV. RESULTADOS E DISCUSSÃO DOS RESULTADOS

O protótipo foi concluído e está disponível aos usuários do *Instagram* por meio do perfil "@verifica_ai_". Ele opera de forma contínua, gratuita e sem a necessidade de instalação. O protótipo tem as seguintes funcionalidades:


1. A comunicação é nativa e realizada via mensagens diretas (DM);
2. O sistema processa diferentes tipos de mídia, incluindo textos, imagens e vídeos.
3. O conteúdo recebido é comparado com fontes recentes, e a veracidade da informação é verificada.
4. Quando a desinformação é identificada, o caso é classificado em uma das sete categorias definidas pelo Manual da UNESCO.
5. A resposta ao usuário é fornecida em um tempo ágil, com média de 30 segundos.
6. As respostas são claras e objetivas, e incluem as fontes utilizadas na pesquisa para validação.

IMAGEM 10 - ENVIANDO DESINFORMAÇÃO AO VERIFICA AI




Fonte: Próprio Autor (2025).

IMAGEM 11 - ENVIANDO NOTÍCIAS VERÍDICAS AO VERIFICA AI



Fonte: Próprio Autor (2025).

IMAGEM 12 - ENVIANDO NOTÍCIAS VERÍDICAS AO VERIFICA AI



Fonte: Próprio Autor (2025).

Para avaliar o desempenho do modelo do utilizado, utilizou-se a matriz de confusão. Ela é uma ferramenta tabular que resume o desempenho de um classificador, contabilizando acertos e erros por classe. Portanto é frequentemente usada para avaliar modelos de classificação de forma objetiva

identificando classes desbalanceadas. A tabela organiza os acertos e erros do modelo em verdadeiros positivos (VP), falsos positivos (FP), verdadeiros negativos (VN) e falsos negativos (FN). (GOOGLE, 2025).

A partir dela derivam-se métricas padrão:

- Acurácia: que expressa a proporção de classificações corretas no total, definida por $Accuracy = (VP + VN) / (VP + VN + FP + FN)$;
- Precisão (precision), que indica a fração de previsões positivas que de fato são positivas, $Precision = VP / (VP + FP)$;
- Sensibilidade ou recall, que mede a capacidade de recuperar os positivos reais, $Recall = VP / (VP + FN)$.

Para cálculo da matriz de confusão, foi empregado um conjunto de 200 postagens, com temas variados, distribuídos de forma igualitária. Desse conjunto, 150 postagens eram verdadeiras e 50 falsas, contemplando os três formatos (texto, imagem e vídeo).

IMAGEM 13 - RESULTADO DA MATRIZ DE CONFUSÃO



Fonte: Próprio Autor (2025).

IMAGEM 14 - CÁLCULO DAS MÉTRICAS DA MATRIZ DE CONFUSÃO

$$\begin{aligned}
 \text{Acurácia: } & \frac{VP+VN}{VP+VN+FP+FN} \\
 \text{Precisão: } & \frac{VP}{VP+FP} \\
 \text{Recall (Sensibilidade): } & \frac{VP}{VP+FN}
 \end{aligned}$$

Fonte: Próprio Autor (2025).

TABELA 1 - RESULTADOS DAS MÉTRICAS DA MATRIZ DE CONFUSÃO

MÉTRICA	Cálculo	%
ACURÁCIA	$Precision = (147 + 47) / (147 + 47 + 3 + 3)$	97%
PRECISÃO	$Precision = 147 / (147 + 3)$	98%
SENSIBILIDADE (RECALL)	$Recall = 147 / (147 + 3)$	98%

Fonte: Próprio Autor (2025).


O modelo apresentou acurácia de 97%, precisão de 98% e sensibilidade (*recall*) de 98%, podendo-se concluir que classifica corretamente a grande maioria dos casos.

A. Limitações e Desafios

A utilização de um modelo de linguagem gratuito resultou em uma vantagem financeira, contudo, isso impõe limitações ao projeto. Apesar do *Gemini Flash 2.5* ser capaz de processar diversas requisições em paralelo, ele estabelece um limite de uso, restringindo a 125 verificações por dia e 5 por minuto. Durante os testes da matriz de confusão, constatou-se uma latência na resposta de aproximadamente 1% das verificações, com tempos de resposta superiores ao dobro da média.

Houve também casos de falha crítica na resposta, correspondendo a 5% das verificações. Nesses casos, o modelo do *Gemini* ficou sobrecarregado com um grande volume de informações, e uma limitação de sua capacidade de processamento impediu a geração de uma resposta, deixando o usuário sem retorno.

IMAGEM 15 - ERRO CRÍTICO NA RESPOSTA



Fonte: Próprio Autor (2025).

A matriz de confusão indicou também a ocorrência pontual de falsos positivos e falsos negativos em situações onde o conteúdo era totalmente fabricado, a busca na *internet* apresentava poucos resultados, e o sistema extraía dados de sites não oficiais para compor a resposta ao usuário, comprometendo a confiabilidade da resposta gerada.

B. Discussão dos Resultados

Os resultados obtidos no desenvolvimento e avaliação do protótipo Verifica AI revelam um desempenho robusto em termos de funcionalidade, mas também expõe limitações ao uso de tecnologias gratuitas. Restrições operacionais como limites de uso diário, e apesar muito raramente, latência nas respostas e erros críticos, inviabilizam o uso em larga escala.

A ocorrência de falsos positivos e falsos negativos encontrados por conta da extração de dados em sites não confiáveis em casos de conteúdos totalmente fabricados, apontam a necessidade de melhorias nos prompts usados no modelo do *Gemini*.

V. CONCLUSÕES

Este projeto alcançou todos os objetivos previamente estabelecidos, resultando na criação de uma ferramenta gratuita e integrada ao *Instagram* para a classificação de desinformação, em conformidade com as sete categorias da UNESCO. A solução proposta supera as limitações de ferramentas existentes, como *Meta AI* e *AI Studio*, ao analisar posts de forma nativa não apenas mensagens, mas também posts com conteúdos multimodal.

Em testes com 200 *posts*, o modelo apresentou acurácia de 97%, precisão de 98% e sensibilidade (*recall*) de 98%, podendo-se concluir que classifica corretamente a grande maioria dos casos.

A escolha do *Gemini Flash 2.5* assegurou a viabilidade econômica do projeto ao garantir custo zero para o desenvolvimento e o uso pelo usuário final. Porém inviabilizou a escalabilidade da solução. A dependência de modelos gratuitos limita o uso diário, além de ocasionalmente causar latência nas respostas e falhas críticas.

Outros desafios não relacionados ao modelo foram identificados, principalmente na classificação de conteúdos completamente fabricados, os quais apresentaram maior dificuldade de serem corretamente classificados.

Para projetos futuros, sugere-se o aprimoramento da versão desenvolvida neste estudo. Recomenda-se o ajuste dos *prompts* e a melhoria do algoritmo para obter maior exatidão, bem como a adoção de um modelo de IA pago para eliminar os limites de uso e melhorar a qualidade das respostas.

VI. REFERÊNCIAS BIBLIOGRÁFICAS

DELMazo, Caroline; VALENTE, Jonas C.L. Fake news nas redes sociais online: propagação e reações à desinformação em busca de cliques. *Media & Jornalismo*, Lisboa, v. 18, n. 32, p. 5-23, abr. 2018. Disponível em: https://scielo.pt/scielo.php?pid=S2183-54622018000100012&script=sci_arttext. Acesso em: 18 setembro. 2025.

GOOGLE. Classification: Accuracy, recall, precision, and related metrics. Google Developers – Machine Learning Crash Course, 2025. Disponível em: <https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall>. Acesso em: 19 out. 2025.

GOOGLE CLOUD. What are AI agents? [S.l.]: Google Cloud, 2025. Disponível em: <https://cloud.google.com/discover/what-are-ai-agents>. Acesso em: 18 out. 2025.

IRETON, Cherilyn; POSETTI, Julie. Journalism, 'fake news' & disinformation: handbook for journalism education and training. Paris: UNESCO, 2018. Disponível em: <https://unesdoc.unesco.org/ark:/48223/pf0000265552>. Acesso em: 18 out. 2025.

OCDE (2024), “The OECD Truth Quest Survey: Methodology and findings”, OECD Digital Economy Papers, No. 369, OECD Publishing, Paris, <https://doi.org/10.1787/92a94c0f-en>.

UNESCO. *Jornalismo, fake news & desinformação: manual para educação e treinamento em jornalismo*. Cherilyn Ireton e Julie Posetti (org.). Brasília: UNESCO, 2018.

WE ARE SOCIAL; HOOTSUITE. Digital 2024: global overview report. [S. l.]: We Are Social; Hootsuite, 2024. Disponível em: <https://wearesocial.com/uk/blog/2024/01/digital-2024/>. Acesso em: 12 Junho. 2025.

WORLD ECONOMIC FORUM. Global risks report 2025. Genebra: World Economic Forum, 2025. Disponível em: <https://www.weforum.org/publications/global-risks-report-2025/>. Acesso em: 10 Junho. 2025.

ANEXO

Passo a Passo para testar o Verifica AI no Instagram:

1. Acesse o perfil do Verifica AI : https://www.instagram.com/verifica_ai/
2. Envie o conteúdo ao perfil do Instagram através de DM (Direct Message). Os conteúdos aceitos são:
 - Post do *Instagram* com *Reels*, fotos ou vídeos.
 - Texto em formato afirmativo descrevendo o que você deseja verificar.. (ex: “A China é comunista”, “Brasil entrará na OTAN devido a ameaça de invasão americana”, “ Trump morreu”) .
 - Enviar imagens do próprio dispositivo que contenham um texto ou imagem a ser analisada.
3. Aguarde aproximadamente 30 segundos, e o chatbot enviará uma resposta dentro da própria DM iniciada.

Nota 1: Como um modelo de LLM gratuito, suas respostas podem apresentar latência e aproximadamente 5% de erro. Além disso, seu propósito é especificamente verificar fake news, conteúdos enviados que não contenham uma afirmação ou notícia a ser analisada, podem resultar em uma resposta imprecisa.

Nota 2: Se a resposta demorar mais de 1 minuto, ocorreu um erro crítico e a análise do conteúdo não será enviada. Os motivos mais prováveis incluem vídeos e Reels muito longos, que geram muitos comandos a serem processados pela LLM gratuita, e por limitação de processamento do Gemini a resposta é interrompida. Meios de lidar com esse erro ainda estão sendo analisados.